

INFORME TÉCNICO

Análisis de sentimiento para la evaluación del desempeño docente

De un sistema de reglas a un modelo predictivo y accionable

Proyecto Capstone — Reto Analítica Educativa
Samsung Innovation Campus · Universidad del Rosario

Curso	AI Course — Samsung Innovation Campus
Equipo	Tech Tailors
Líder del equipo	Juan David Ríos Gómez
Integrantes	Natalia Remolina · Giovanni Balza
Autoría de este informe	Natalia Remolina — componente de procesamiento de lenguaje natural y DOFA
Fecha	4 de agosto de 2026
Repositorio	github.com/Capstone-Tech-Tailors/Analitica-Educativa
Modelo de producción	<code>modelo_sentimiento_humano</code> (RoBERTuito + etiquetas humanas)

Contenido

	Sección	
	Ficha del proyecto	Objetivo · Método · Datos · Entregables · Roles
	Resumen ejecutivo	
1	Introducción	1.1 Contexto del reto · 1.2 Problema · 1.3 Objetivos · 1.4 Alcance
2	Idea y arquitectura de la solución	Pipeline encuesta → sentimiento → tendencia → DOFA → nube
3	Datos	3.1 Dataset institucional · 3.2 Cadena de derivación del corpus · 3.3 Perfil estadístico · 3.4 Traducción y auditoría · 3.5 Datasets derivados
4	Metodología	4.1 EDA y auditoría · 4.2 Benchmark · 4.3 Modelo de tendencia · 4.4 Destilación · 4.5 Anotación humana · 4.6 Fine-tuning humano
5	RESULTADOS	5.1 Benchmark · 5.2 Tendencia · 5.3 Destilación · 5.4 Falsos positivos · 5.5 Anotación · 5.6 Modelo final · 5.7 Análisis institucional · 5.8 Eficiencia · 5.9 Modelos complementarios
6	Modelo de producción	6.1 Ficha técnica · 6.2 Justificación · 6.3 Verificación · 6.4 Paquete de despliegue
7	Despliegue: el sistema en producción	7.1 Arquitectura del sistema · 7.2 Cómo se sirve el modelo
8	Aplicación: del sentimiento al DOFA	8.1 Metodología propuesta · 8.2 Implementación en el backend · 8.3 Prototipo sobre datos reales · 8.4 Docentes «enmascarados»
9	Limitaciones	9.1 Datos · 9.2 Modelo · 9.3 Alcance
10	Consideraciones éticas	
11	Conclusiones	
12	Trabajo futuro	
13	Referencias	

Ficha del proyecto

Esta sección alinea el informe con el **Capstone Project Action Plan** del AI Course de Samsung Innovation Campus: reproduce sus campos oficiales —marcados con ▶— y señala dónde se desarrolla cada uno. Los datos de curso, equipo e integrantes figuran en la portada.

Campo	Valor
▶ Título del proyecto (<i>Project Title</i>)	Análítica Educativa
Entidad	Universidad del Rosario
▶ Código fuente	GitHub · Capstone-Tech-Tailors/Analitica-Educativa
Interfaz de usuario	Dashboard en PowerBI · repositorio entregable-visual

Objetivo (Goal)

«Diseñar e implementar una solución avanzada de análisis de evaluaciones docentes que evolucione el sistema actual basado en reglas hacia un modelo de aprendizaje automático, manteniendo compatibilidad con los datos y procesos existentes. El reto consiste en pasar de un análisis descriptivo a uno predictivo y accionable, que permita anticipar tendencias en el desempeño docente y generar recomendaciones de mejora continua.» — *Capstone Project Action Plan*

Este informe documenta **el componente de procesamiento de lenguaje natural y DOFA**, uno de los cinco entregables del proyecto. Los objetivos técnicos derivados se detallan en la sección 1.3.

Método (Method)

El Action Plan establece una metodología ágil **Scrum/Kanban** con seguimiento y control de las actividades en **JIRA**. Este informe no documenta la gestión del proyecto, sino la **ejecución técnica** del componente de lenguaje, organizada en **seis fases encadenadas** —análisis exploratorio y auditoría, evaluación comparativa de modelos, modelo de tendencia, destilación, anotación humana y ajuste fino con verdad humana—, donde cada fase justifica sus decisiones con evidencia obtenida en la anterior (sección 4).

Datos (Data)

Aspecto	Situación
► Fuente institucional	Información suministrada por la universidad (operador del reto) a través de un SharePoint del proyecto; en el sistema en producción los CSV ingresan por <code>POST /etl</code> (sección 7.1)
► Propiedad intelectual	Los datos y los resultados son propiedad de la entidad; los CSV institucionales no están versionados (*.csv en .gitignore)
Corpus de entrenamiento y evaluación del modelo de sentimiento	ReadyToTrain_comentarios_EN_ES_completo.xlsx — 100.000 filas del corpus público de AIUB (referencia 1, licencia CC BY-NC 3.0), traducido al español por el equipo. Es la única fuente de texto del modelo de producción

Desvío declarado respecto al Action Plan. El plan preveía trabajar únicamente con la información del operador. El diagnóstico de datos lo hizo inviable para el componente de lenguaje: la unicidad del campo de comentarios institucional es del **0,67 %** (detalle e implicaciones en la sección 3.1). Se incorporó entonces un corpus público con licencia compatible con uso académico. Tres salvaguardas acompañan la decisión:

(i) El **modelo de sentimiento** de producción no se entrenó con datos institucionales: su único texto proviene del corpus externo. El dataset institucional sí alimentó el análisis exploratorio, el benchmark inicial (sección 5.1), el modelo de tendencia (sección 5.2) y el prototipo DOFA (secciones 5.7 y 8.3). Los modelos complementarios de la sección 5.9 no usan ese archivo, sino una versión sintética ampliada derivada de él. (ii) Los datos institucionales no se enviaron a terceros para etiquetado ni traducción y no están versionados; su procesamiento ocurre en el despliegue operado por el equipo — la sección 10 recomienda migrarlo a infraestructura controlada por la universidad. (iii) El corpus externo aportó materia prima de texto, no etiquetas: las del modelo de producción son **anotación propia del equipo** (sección 5.5). La limitación de dominio que introduce queda declarada (L2, sección 9.1) y su resolución es la prioridad 3 del trabajo futuro.

Entregables (Expected Outcome)

#	Entregable del Action Plan	Responsable	Dónde	Estado
a	Probabilidad de rotación de profesores entre <i>materias</i> de una misma facultad	Equipo	5.9	Regresor de egresos entrenado sobre datos sintéticos ampliados , con acoplamiento parcial declarado (R^2 0,942 = techo optimista). El índice de egreso queda propuesto, no calculado
b	Anticipar el porcentaje de deserción para una clase específica	Equipo	5.9	Analizada: las correlaciones por asignatura identifican sus factores (volumen del curso 0,76; carga lectiva 0,63) y muestran que desertar y reprobar son fenómenos distintos ($r = 0,17$). El modelo predictivo queda pendiente
c	Anticipar la demanda estudiantil (estudiantes futuros por <i>materia</i>)	Equipo	5.9	Explorado sin resultado válido: el modelo reproduce una identidad aritmética (fuga de datos declarada) y el reentrenamiento quedó como recomendación
d	Análisis FODA consolidado por profesor	Natalia Remolina (metodología, modelo, verificación) · Juan David Ríos Gómez (implementación en el backend)	5.1–5.9 · 6 · 7 · 8	Completado y en producción: el DOFA consolidado se proyecta en el dashboard PowerBI a partir de las salidas del modelo. El servicio en línea desde el backend queda operativo al publicar los pesos en el contenedor (sección 7.2). La asignación de cuadrantes tiene una desviación declarada (Oportunidades = NEU, sección 8.2)
e	Interfaz de usuario con los resultados	Juan David Ríos Gómez	7.1	Entregada como demonstración pública (dashboard PowerBI); su contenido no se inspeccionó para este informe y no hay ciclo completo con datos reales (sección 9.3). Según la arquitectura de 7.1, su panel de FODA consumiría <code>/analisis_foda</code>

Notas de la tabla: el Action Plan denomina **FODA** a lo que el resto de este informe llama **DOFA** —misma matriz—; y usa *materias* donde el informe usa *asignaturas*. Dos precisiones de alcance: el marco de la sección 5.9 no tiene dimensión de facultad, de modo que (a) se modela entre asignaturas sin restringirlas a una facultad; y «Estudiantes Aprobados» es un indicador retrospectivo, no la proyección futura que pide (c). El plan preveía la interfaz como aplicativo web; el equipo entregó un dashboard PowerBI publicado, que cumple la misma función.

Beneficios esperados declarados en el plan: planeación más ágil de la asignación docente, retroalimentación personalizada que incentive mejoras pedagógicas, reducción de la deserción en materias de bajo desempeño, mejor proyección de ocupación de aulas y, a largo plazo, insumos para revisar la malla curricular.

Roles (Role by Member)

Integrante	Responsabilidad
Juan David Ríos Gómez (líder)	Apoyo a los integrantes, gestión de avances y reuniones con la universidad, evaluación de resultados y presentación de estos en una interfaz de usuario (aplicativo web). Vela por la calidad y completitud de la información (preprocesamiento, limpieza, transformación, imputación) y por la determinación de las métricas de negocio
Giovanni Balza	Análisis estadístico exploratorio: componentes temporales (tendencia, estacionalidad, ciclicidad), segmentación de perfiles docentes, detección de tendencias emergentes y estudio de las variables que más influyen en cada variable objetivo
Natalia Remolina	Automatización del análisis FODA por docente : análisis de sentimiento de los comentarios mediante procesamiento de lenguaje natural, selección del mejor modelo preentrenado y ajuste fino (<i>fine-tuning</i>) del modelo elegido — objeto de este informe
Rol compartido	Evaluación de modelos predictivos para cada variable objetivo y selección del de mejor desempeño

Resumen ejecutivo

Este informe documenta el diseño, la construcción, la evaluación y el despliegue de un sistema de **análisis de sentimiento en español** para los comentarios de las encuestas de evaluación docente, cuyo propósito final es alimentar la construcción del **DOFA de cada docente** de la Universidad del Rosario y un modelo complementario de **tendencia de desempeño** (Mejora / Estable / En riesgo).

El proyecto recorrió el ciclo completo de un desarrollo de ciencia de datos aplicada:

1. **Diagnóstico de datos.** El análisis exploratorio reveló que el dataset institucional del reto contiene solo **20 comentarios distintos repetidos en 3.000 filas** (unicidad 0,67 %), lo que imposibilita entrenar o evaluar seriamente un modelo de lenguaje. Este hallazgo redefinió la estrategia y motivó la incorporación de un corpus real —única fuente de texto del modelo de producción— de **100.000 comentarios** (29.243 textos únicos), traducido al español por el equipo.
2. **Evaluación comparativa** de tres modelos de sentimiento aplicables al español —RoBERTuito y BETO (preentrenados en español) y XLM-R (multilingüe)— contra un estándar de oro manual: RoBERTuito resultó el mejor modelo individual (accuracy 0,75) y el consenso por votación el mejor macro-F1 (0,730).
3. **Modelo de tendencia docente:** RandomForest con macro-F1 **0,915** en partición aleatoria y **0,905** en validación temporal (entrenar 2020-2022, probar 2023), con detección y exclusión de una variable con fuga de información. El punto de operación elegido —tras calibración isotónica y umbral 0,21— rinde macro-F1 0,899 con recall En riesgo 0,966. Este modelo aún no está integrado en el backend (sección 7), que hoy sirve únicamente el de sentimiento.
4. **Fine-tuning por destilación:** se demostró empírica y sistemáticamente que un modelo entrenado con pseudo-etiquetas de un maestro **no puede superar al maestro** (fidelidad de imitación de hasta 0,933, sin ganancia de calidad real), incluyendo un análisis de falsos positivos que probó que el error residual es un problema de **definición de rúbrica** y no de modelado.
5. **Anotación humana:** el equipo diseñó y ejecutó un protocolo formal de etiquetado (335 comentarios, 3 anotadores independientes, 749 anotaciones) con acuerdo inter-anotador **α de Krippendorff = 0,585** y un estándar de oro adjudicado de **172 comentarios**, 8,6 veces mayor que el disponible previamente.
6. **Modelo final:** el ajuste fino de RoBERTuito con las etiquetas humanas produce el **mejor clasificador disponible** sobre la evaluación humana (macro-F1 **0,646**; accuracy 0,762; recall de comentarios negativos 0,556), superando de manera consistente —aunque aún no estadísticamente significativa (McNemar $p = 1,0$)— al mejor modelo público (0,638).

El modelo final se empaquetó en un ZIP de 404 MB (modelo en disco: 437 MB, ejecutable en CPU) y está integrado en el **sistema en producción del equipo**: un backend FastAPI (`src/app.py` del repositorio) con despliegue continuo en **Azure Container Apps**, que expone los endpoints `/predecir_sentimientos` y `/analisis_foda` y está previsto que alimente un dashboard en PowerBI. Queda pendiente cargar los pesos en el almacenamiento del contenedor. El informe documenta ese sistema (sección 7), la metodología de construcción del DOFA con su implementación real (sección 8, con un prototipo sobre datos reales) y una declaración exhaustiva de limitaciones, entre ellas que el cuello de botella actual es el **volumen de anotación humana**, con el sistema para ampliarla ya construido y operativo.

1 · Introducción

1.1 Contexto del reto

El reto *Analítica Educativa*, cuya formulación literal se reproduce en la ficha del proyecto, exige pasar de describir a **anticipar**. El sistema vigente clasifica el desempeño docente con reglas sobre los puntajes numéricos: es transparente y auditable, pero solo puede repetir el umbral que alguien fijó de antemano, no descubrir patrones ni explicar por qué un

docente se desvía. Y, sobre todo, deja fuera la mitad de la encuesta —los **comentarios de texto libre**, que es donde el estudiante explica su calificación—. Ese texto sin explotar es la materia prima de este informe.

1.2 Problema

Las encuestas de evaluación docente combinan **puntajes numéricos** (claridad, metodología, evaluación) con **comentarios de texto libre**. Los puntajes se procesan de forma rutinaria; los comentarios —que contienen la información más rica y accionable— quedan habitualmente sin explotar, porque requieren lectura humana masiva o tecnología de procesamiento de lenguaje natural. El problema abordado es doble:

1. **Clasificar automáticamente el sentimiento** de cada comentario (positivo / neutro / negativo) con calidad suficiente para agregarlo por docente.
2. **Predecir la tendencia de desempeño** combinando puntajes y sentimiento, para priorizar el acompañamiento pedagógico.

1.3 Objetivos

Objetivos técnicos derivados del entregable **(d) Análisis FODA por profesor** de la ficha del proyecto, que es el componente documentado en este informe.

#	Objetivo	Estado
O1	Diagnosticar la calidad e idoneidad de los datos disponibles	✅ Cumplido (sección 3)
O2	Evaluar comparativamente modelos de sentimiento preentrenados en español y seleccionar el mejor	✅ Cumplido (sección 5.1)
O3	Construir un modelo de tendencia docente validado temporalmente	✅ Cumplido, con dos reservas declaradas: la etiqueta es derivada por reglas (techo artificial, L4) y el objetivo de recall $\geq 0,985$ solo se alcanza en el protocolo temporal (sección 5.2)
O4	Ajustar (<i>fine-tuning</i>) el modelo seleccionado	✅ Cumplido (secciones 5.3 a 5.6)
O5	Construir un estándar de oro humano con acuerdo medido	✅ Cumplido (sección 5.5)
O6	Empaquetar y desplegar el modelo en la nube	🟡 Parcial: empaquetado y backend con CI/CD en Azure Container Apps; la carga de los pesos al contenedor sigue pendiente (sección 7)
O7	Automatizar la construcción del DOFA a partir de las salidas del modelo	✅ Cumplido, con una desviación declarada en la implementación (Oportunidades = NEU, sección 8.2)

O2, O4 y O7 corresponden literalmente a las tres tareas que el Action Plan asigna a Natalia Remolina: determinar la mejor opción de modelo preentrenado, ajustarlo mediante

fine-tuning

y automatizar el análisis FODA por docente.

1.4 Alcance y no-alcance

Incluye: análisis exploratorio y auditoría del dataset institucional; benchmark de modelos; modelo de tendencia; dos rondas de fine-tuning (destilación y verdad humana); protocolo completo de anotación humana; empaquetado del modelo y documentación del despliegue en producción (sección 7); metodología DOFA con implementación y prototipo.


No incluye: los otros cuatro entregables del proyecto. Rotación docente y demanda estudiantil (a y c de la ficha) se ejecutaron bajo el **rol compartido** de evaluación de modelos predictivos que el Action Plan asigna a los tres integrantes, y aquí solo se reseñan en la sección 5.9, donde la deserción (b) se aborda a nivel exploratorio y su modelado queda pendiente; la **interfaz de usuario** (e) y el backend son obra del líder del equipo, aunque la sección 7 documenta cómo ese sistema sirve el modelo. Tampoco incluye la integración con el sistema de encuestas real de la universidad ni el análisis basado en aspectos (ABSA), que el corpus utilizado no permite (sección 3.2).

2 · Idea y arquitectura de la solución

La solución es un **pipeline de dos modelos complementarios** cuyas salidas agregadas alimentan el DOFA del docente. Los principios de diseño que gobernaron el proyecto:

- **Medir antes de elegir:** ningún modelo se adoptó sin un benchmark contra referencia humana.
- **Honestidad estadística:** toda comparación va acompañada de su prueba de significancia; los resultados no significativos se declaran como tales.
- **Trazabilidad total:** semillas fijadas, sumas de comprobación, fichas `info.json` por modelo y ejecución reproducible de todos los notebooks.
- **El humano define la vara:** la calidad se mide contra etiquetas humanas con acuerdo inter-anotador cuantificado, no contra las predicciones de otro modelo.

El pipeline completo, de la encuesta al DOFA:



3 · Datos

El proyecto utiliza **tres conjuntos de datos fuente** con roles distintos. Esta distinción es esencial: **el modelo de sentimiento de producción no se entrenó con el dataset institucional**.

#	Dataset	Origen	Alimentó
1	evaluaciones_docentes.csv	Universidad (reto)	EDA · benchmark inicial · modelo de tendencia · prototipo DOFA
2	ReadyToTrain_comentarios_EN_ES_completo.xlsx	Corpus Mendeley (AIUB), procesado por el equipo	Destilación · anotación humana · modelo de producción
3	evaluaciones_docentes_sintetica_ampliada.csv	Ampliación sintética del institucional, hecha por el equipo (añade variables operativas)	Modelos complementarios de rotación y demanda (sección 5.9)

3.1 Dataset institucional

3.000 evaluaciones de 50 docentes, 7 asignaturas y 8 semestres (2020-1 a 2023-2), con tres puntajes en escala 1-5, un comentario y la etiqueta `tendencia_desempeno` (Estable 1.500 · Mejora 904 · En riesgo 596). Calidad estructural impecable: 0 nulos, 0 duplicados exactos, rangos válidos.

Hallazgo determinante. El campo `comentario` contiene únicamente **20 textos distintos**:

Métrica	Valor
Filas (comentarios escritos)	3.000
Textos distintos	20 (unicidad 0,67 %)
Filas que son repetición	2.980 (99,33 %)
Repeticiones por texto	media 150 · mín 101 · máx 233
Dispersión de cada texto	en promedio aparece en 48/50 docentes, 8/8 semestres y 7/7 asignaturas

Tres señales indican que el campo no es texto libre real sino **plantillado/anonimizado**: (i) cero variaciones ortográficas y cero celdas vacías; (ii) cada frase repartida de forma casi uniforme entre docentes, semestres y asignaturas; (iii) independencia entre comentario y puntaje (p. ej. "*Llega tarde a las clases frecuentemente*" coexiste con puntajes de hasta 4,4).

Implicación. Para el análisis de texto, el conjunto real de evaluación son 20 elementos, no 3.000: el dataset sirve para **validar el método**, no para demostrar desempeño de NLP. Esto motivó la incorporación del segundo dataset.




Figura 1. Los 20 comentarios distintos del dataset institucional y su frecuencia, coloreados por polaridad. Dos características delatan el plantillado: la distribución casi uniforme entre docentes y la independencia entre el texto y el puntaje de su fila.

3.2 Corpus de entrenamiento: origen y cadena de derivación

Recurso fuente: *A Novel Dataset for ABSA for Teacher Performance Evaluation*, publicado por American International University-Bangladesh (AIUB) en Mendeley Data (data.mendeley.com/datasets/b2yh95rnx/1), con más de 2.000.000 de instancias reportadas y licencia CC BY-NC 3.0.

Mendeley – dataset original (ABSA, >2.000.000 instancias, con etiquetas y aspectos)

- └ [1] Selección de un subconjunto de 100.000 filas (equipo)
- └ [2] Traducción inglés → español con Claude (Anthropic) (equipo)
 - └ ReadyToTrain_comentarios_EN_ES_completo.xlsx ← ARCHIVO UTILIZADO
 - columnas: id · StudentComments_EN · Comentarios_ES
 - SIN columna de etiqueta · SIN columna de aspecto

Consecuencia metodológica. El subconjunto **no conserva las etiquetas ni los aspectos** del recurso original; por tanto no era directamente utilizable para aprendizaje supervisado. Esa ausencia es la razón de las dos estrategias de etiquetado del proyecto (secciones 4.4 y 4.5). La tarea implementada es clasificación de **polaridad global**, no ABSA.

3.3 Perfil estadístico del corpus (verificado sobre el archivo)

Archivo de 3,3 MB · SHA-256 21637107cebf941a3aab9f397983c123b1676f5f4488d2d1...

Indicador	Valor
Filas	100.000 (99.992 comentarios ES no vacíos; 8 nulos en cada columna de texto, 0 en id)
Textos únicos (español)	29.243 → unicidad 29,2 %
Casi duplicados	28.147 grupos tras normalización (1.096 variantes colapsan)
Repetición máxima	la frase más frecuente aparece 9.741 veces
Longitud (palabras)	media 6,8 · mediana 4 · p5 1 · p95 22 · máx 199
Longitud (caracteres)	media 39 · mediana 20 · p95 129 · máx 1.121

Verificación de idioma. Sobre una muestra aleatoria de 3.000 textos: 80,2 % contienen marcadores léxicos del español frente a 5,7 % con marcadores del inglés (columna de control en inglés: 89,6 %). **La columna utilizada está en español.**

3.4 Traducción: sistema y auditoría de preservación

Elemento	Valor
Sistema	Claude (modelo de lenguaje de Anthropic)
Dirección y momento	Inglés → español, antes de particionar y deduplicar
Cobertura	Las 100.000 filas

Auditoría de preservación de los marcadores que invierten o matizan la polaridad, sobre el corpus completo:

Marcador	En el original (EN)	Preservados (ES)	Tasa
Negaciones (<i>not, never, no, n't, cannot, without...</i>)	8.296 (8,3 %)	8.221	99,1 %
Adversativas (<i>but, although, however, though...</i>)	4.989 (5,0 %)	4.781	95,8 %

La revisión cualitativa confirma la conservación de la cláusula que determina la polaridad ("*...vast knowledge about programming but not students*" → "*...conocimientos sobre programación, pero no sobre los estudiantes*"). El 1,6 % de negaciones que aparecen solo en español corresponde a reformulaciones idiomáticas legítimas ("*lacks clarity*" → "*no es claro*"). **Las tasas no comprometen la validez del entrenamiento.** La limitación que sí persiste: la traducción produce un registro estándar, sin la variación coloquial regional que tendrán las encuestas reales (sección 9.1, L2).

3.5 Datasets derivados

Archivo (data/processed/)	Contenido	Rol
evaluaciones_con_sentimiento.csv	Dataset institucional + sentimiento clasificado	Análisis y modelo de tendencia
benchmark_sentimiento.csv	20 comentarios con gold manual y predicción por modelo	Benchmark, sección 5.1
muestra_annotacion.csv	335 comentarios muestreados para anotar	Anotación, sección 4.5
train_humano.csv	148 etiquetas humanas	Entrenamiento del modelo de producción
gold_humano_eval.csv	172 comentarios adjudicados	Evaluación de referencia

4 • Metodología

El proyecto se ejecutó en seis fases encadenadas. Cada una respondió a una pregunta concreta y sus decisiones se justifican con evidencia obtenida en la fase anterior.

4.1 Fase 1 — Análisis exploratorio y auditoría

Se partió del análisis exploratorio del dataset institucional y se sometió a una **auditoría sistemática**: cada afirmación del EDA se recomputó desde los datos y la mayoría de los hallazgos se sometió además a refutadores independientes antes de aceptarse. Los cuatro hallazgos metodológicos de mayor severidad (sección 5.7) quedaron sin esa segunda vuelta por un límite de sesión; se recomputaron de forma independiente y así se declara.

La auditoría confirmó la calidad estructural (0 nulos, 0 duplicados, rangos válidos, paleta visual validada para daltonismo con $\Delta E_{CVD} \geq 23,8$) y detectó **seis problemas** que se corrigieron antes de continuar: cuatro conclusiones sobre-afirmadas, la ubicación errónea de la «zona gris» y un artefacto en la señal de sentimiento (secciones 5.7 y 5.8).

4.2 Fase 2 — Benchmark de modelos preentrenados

Se compararon tres modelos de sentimiento en español contra un **estándar de oro etiquetado manualmente por rúbrica**, elaborado de forma independiente de los modelos para evitar circularidad al elegir entre ellos.

Modelo	Identificador en Hugging Face
RoBERTuito	pysentimiento/robertuito-sentiment-analysis
BETO	finiteautomata/beto-sentiment-analysis
XLNet (Twitter)	cardiffnlp/twitter-xlm-roberta-base-sentiment

Rúbrica de etiquetado. POS = elogio o satisfacción clara; NEG = queja o crítica, **incluida la crítica constructiva** («se podría mejorar», «falta...»); NEU = descriptivo o administrativo, elogio tibio («estuvo bien», «cumple») o mixto sin polaridad dominante.

Se evaluó además una estrategia de **consenso** por votación mayoritaria de los tres modelos, con RoBERTuito como criterio de desempate.

4.3 Fase 3 — Modelo de tendencia docente

Clasificador de `tendencia_desempeno` a partir de puntajes y sentimiento. Se compararon cinco candidatos bajo **dos protocolos de validación** y con una restricción de negocio explícita: `recall` de la clase En riesgo $\geq 0,985$ (el costo de no detectar a un docente que necesita acompañamiento supera al de una falsa alarma).

Selección de variables. Se excluyeron deliberadamente:

Variable excluida	Motivo
delta_semestre	Fuga de información: incorpora el promedio del semestre que se está clasificando; en grupos docente-semestre de tamaño 1 la variable es el puntaje propio
hist_prom_previo	Sin poder predictivo demostrado

Variable excluida	Motivo
id_docente , semestre	Alta cardinalidad sin señal real (V de Cramér de id_docente = 0,119 con p = 0,813; el valor esperado bajo independencia pura es 0,127, mayor que el observado)

4.4 Fase 4 — Fine-tuning por destilación (*weak supervision*)

Ante la ausencia de etiquetas en el corpus, se aplicó **destilación de conocimiento** (Hinton et al., 2015): RoBERTuito — el mejor modelo del benchmark — actuó como **maestro** etiquetando el corpus deduplicado, y BETO como **alumno** entrenado con esas pseudo-etiquetas.

Límite teórico declarado como hipótesis falsable. El alumno aprende la *función* del maestro, heredando sus aciertos y sus errores; su techo de calidad es, por construcción, el desempeño del maestro. La sección 5.3 contrasta esta hipótesis empíricamente, incluyendo una comparación de arquitecturas del alumno.

4.5 Fase 5 — Anotación humana

Única vía para romper el techo de la destilación. El equipo diseñó y ejecutó un **protocolo formal de anotación** (v1.0):

Muestreo estratificado de 335 comentarios. No es una muestra aleatoria simple: está deliberadamente enriquecida en casos fronterizos, que es donde se decide la rúbrica.

Estrato	Ítems	Contenido
H0_CENSO	40	Los 40 enunciados más frecuentes — concentran el 53 % de todas las evaluaciones
H1_CORTO	20	Textos de 1–2 palabras (pesan el 30 % de las filas)
H2a_T0	40	Casos triviales (control del estimador)
H2b_F1	80	Frontera débil: POS con alta confianza y léxico tibio
H3_F2	145	Frontera fuerte: máxima ambigüedad
H4_LARGO	10	Textos largos (control de longitud)
Total	335	

Justificación del censo. Dos enunciados —«Es un buen profesor» (15.826 filas) y «Bueno.» (9.745 filas)— determinan por sí solos el **25,6 %** del corpus. Un sorteo aleatorio tendría probabilidad casi nula de incluirlos, y sin ellos ninguna métrica podría traducirse a desempeño real. El sesgo de sobre-representación se corrige al estimar mediante ponderación estratificada ($w_h = N_h / n_h$).

Diseño de la anotación.

Bloque	Diseño	Realizado	Anotación	Destino
EVAL	185	184 anotados por los 3 → 178 tras exclusiones → 172 gold	Los 3 anotadores (triple)	Evaluación + medición de acuerdo
TRAIN	150	149 anotados (49/50/50) → 148 utilizables	Un anotador por tercio	Entrenamiento con verdad humana

Los dos textos ilegibles de la muestra se retiraron antes de generar las planillas, por lo que 333 de los 335 ítems de diseño llegaron a anotarse.

Se incluyeron **8 ítems ancla** de etiqueta obvia (control de atención) y **8 repetidos encubiertos** (autoconsistencia). Decisiones de control: **no se muestra la predicción del modelo** —RoBERTuito acierta 15/16 en casos claros pero **0/4 en fronterizos**, y la muestra está enriquecida precisamente en fronterizos, por lo que mostrar su predicción induciría *anchoring bias* justo donde importa—; **orden aleatorizado independiente** por anotador con claves opacas; formato **XLSX** (el 30 % de los textos contienen comas y el 51 % llevan tildes, lo que corrompe el viaje por CSV).

4.6 Fase 6 — Fine-tuning con verdad humana

Ajuste fino de robertuito-sentiment-analysis (*continued fine-tuning*) con las 148 etiquetas humanas. Al provenir la evaluación de personas y no del maestro, **desaparece la circularidad** que limitaba la fase anterior.

Por qué esta vez sí se ajusta RoBERTuito. En la Fase 4 el alumno debía ser un modelo distinto del maestro para evitar la auto-destilación. Al desaparecer esa restricción, conviene partir del modelo con mejor desempeño previo: con solo 148 ejemplos, un modelo que **ya sabe clasificar sentimiento** únicamente necesita ajustar la frontera POS/NEU, mientras que uno sin cabeza de clasificación no aprendería la tarea desde cero.

5 · RESULTADOS

5.1 Benchmark de modelos preentrenados

Evaluación sobre el estándar de oro manual de 20 comentarios (distribución POS 7 · NEU 4 · NEG 9):

Modelo	Accuracy	macro-F1	Aciertos	En claros (n=16)	En fronterizos (n=4)
RoBERTuito	0,75	0,706	15/20	0,94 (15/16)	0/4
XLM-R (Twitter)	0,70	0,664	14/20	0,75 (12/16)	2/4
BETO	0,65	0,626	13/20	0,69 (11/16)	2/4
Consenso (3 modelos)	0,75	0,730	15/20	0,81 (13/16)	2/4




Figura 2. Accuracy y macro-F1 de cada modelo sobre los 20 comentarios reales.

	robertuito			beto			xlmr			consenso		
pred	POS	NEU	NEG	POS	NEU	NEG	POS	NEU	NEG	POS	NEU	NEG
predicho	POS	NEU	NEG	POS	NEU	NEG	POS	NEU	NEG	POS	NEU	NEG
	6	1	0	6	1	0	5	2	0	5	2	0
	2	2	0	2	2	0	1	2	1	1	3	0
predicho	POS	NEU	NEG	POS	NEU	NEG	POS	NEU	NEG	POS	NEU	NEG
	0	2	7	0	4	5	0	2	7	0	2	7

Figura 3. Matrices de confusión de los cuatro enfoques. La clase NEU concentra la confusión.

Acuerdo entre modelos: 11 de 20 comentarios con unanimidad (3/3), 9 con mayoría (2/3) y ninguno sin acuerdo (1/1/1).

Hallazgo principal. Los errores se concentran en los **4 comentarios fronterizos** —elogios tibios («La clase estuvo bien»), críticas constructivas («Se podría mejorar un poco el material de estudio») y mixtos con adversativa («Asistencia puntual, pero falta dinamismo») —: ningún enfoque acierta más de 2 de los 4 y RoBERTuito falla los cuatro. Pero **no se agotan ahí**: cada enfoque comete además entre 1 y 5 errores en comentarios claros (RoBERTuito 1 · consenso 3 · XLM-R 4 · BETO 5). Dos fronterizos —«La clase estuvo bien» y «Se podría mejorar un poco el material de estudio»— fallan en los cuatro enfoques.

RoBERTuito es el más fuerte en comentarios claros (0,94). El consenso resuelve 2 de los 4 fronterizos, aunque a costa de 2 comentarios claros (0,81 frente a 0,94); con los mismos 15/20 aciertos, su macro-F1 es superior (0,730 vs 0,706) por un reparto más equilibrado del error entre clases, no por acertar más.

Conclusión. La dificultad no está en el modelo sino en la **ambigüedad del lenguaje**: dos personas razonables etiquetarían esos casos de forma distinta. Este hallazgo determina toda la estrategia posterior del proyecto.

5.2 Modelo de tendencia docente

Protocolo A — partición estratificada 75/25 con validación cruzada de 5 pliegues:

Modelo	CV macro-F1	Test macro-F1	Test accuracy	Recall En riesgo
Regla 2 umbrales	0,914 ± 0,003	0,904	0,896	0,953
Regla híbrida (+ sentimiento)	0,878 ± 0,009	0,889	0,881	0,953
Regresión logística	0,916 ± 0,013	0,908	0,900	0,973
RandomForest	0,910 ± 0,006	0,915	0,907	0,960
Gradient Boosting	0,903 ± 0,011	0,910	0,903	0,960

Protocolo B — validación temporal (entrenar 2020–2022 con 2.265 filas, probar 2023 con 735):

Modelo	Test aleatorio	2023	Δ (temporal – aleatorio)
Regla 2 umbrales	0,904	0,907	+0,003
Regresión logística	0,908	0,903	–0,005
RandomForest	0,915	0,905	–0,010
Gradient Boosting	0,910	0,894	–0,016




Figura 4. macro-F1 en test de los cinco candidatos.

Campeón: RandomForest calibrado. Criterio: mayor macro-F1 entre los candidatos, con desempate a favor de un modelo **probabilístico** (produce probabilidades calibrables para priorizar docentes, algo que una regla dura no ofrece). Informe por clase en test (n = 750):

Clase	Precisión	Recall	F1	Soporte
En riesgo	0,98	0,96	0,97	149
Estable	0,92	0,89	0,91	375
Mejora	0,84	0,90	0,87	226
macro avg	0,91	0,92	0,91	750




Figura 5. Matriz de confusión del RandomForest en el conjunto de prueba.

Calibración. Se aplicó calibración isotónica con validación cruzada de 5 pliegues, mejorando el *Brier score* de 0,0133 a 0,0123. El umbral de decisión de En riesgo se ajustó a **0,21** mediante probabilidades fuera de muestra, elevando el recall de 0,960 a **0,966** en test, a cambio de una caída marginal de macro-F1 a 0,899. En el protocolo temporal el RandomForest ya alcanza un recall de 0,993 sobre 2023 **sin** ese ajuste; el ajuste de umbral no se evaluó por separado en ese protocolo.

Declaración de honestidad estadística. Ningún candidato alcanzó de fábrica el objetivo de recall $\geq 0,985$ (rango observado 0,953–0,973); se documenta como pendiente y se mitiga con el ajuste de umbral. Además, la ventaja del RandomForest sobre una simple regla de dos umbrales **no es estadísticamente significativa**: McNemar $p = 0,280$, y en 15 semillas de partición la regla supera al modelo en 2 de ellas —ambos resultados provienen del experimento equivalente de la auditoría del análisis exploratorio (RF 0,920 vs regla 0,910 sobre 649 filas); el NB03 no reejecutó la prueba sobre su propia partición—. La causa de fondo es la **circularidad**: la etiqueta `tendencia_desempeno` se generó por reglas a partir de los propios puntajes, de modo que estas métricas constituyen un **techo artificial** del dataset, no una medida del valor del aprendizaje automático.




Figura 6. Curva de fiabilidad de P(En riesgo) antes y después de la calibración isotónica.

5.3 Fine-tuning por destilación

Corpus y particiones. De los 100.000 registros se obtuvieron 29.243 textos únicos (reducción del 70,8 % por deduplicación). El maestro produjo una distribución muy desbalanceada (POS 20.284 = 69,4 % · NEG 5.060 = 17,3 % · NEU 3.899 = 13,3 %; ratio 5,2×), por lo que se balanceó al tamaño de la clase minoritaria:

Partición	n	%	NEG	NEU	POS
Entrenamiento	8.187	70 %	2.729	2.729	2.729
Validación	1.755	15 %	585	585	585
Prueba	1.755	15 %	585	585	585

Fuga entre particiones: 0 textos compartidos (verificado explícitamente).

Entrenamiento (BETO, dccuchile/bert-base-spanish-wwm-cased, 109,9 M parámetros): 4 épocas, lr 2e-5, batch 32, max_length 64, weight decay 0,01, warmup 10 %, early stopping con paciencia 2, semilla 42, GPU Apple Silicon (MPS). Duración: **7,2 minutos**.

Época	Pérdida train	Pérdida val	macro-F1 val
1	0,5304	0,3551	0,8729
2	0,2489	0,3193	0,8738
3	0,1493	0,3553	0,8892 ← mejor
4	0,0852	0,4101	0,8853

Fidelidad al maestro en prueba (n = 1.755): accuracy 0,9054 · macro-F1 **0,9055**.

Clase	Precisión	Recall	F1	Soporte
NEG	0,889	0,926	0,907	585
NEU	0,875	0,862	0,868 ← menor	585
POS	0,954	0,928	0,941	585




Figura 7. Curvas de aprendizaje. La pérdida de validación sube en la época 4 mientras la de entrenamiento sigue bajando: sobreajuste incipiente. El entrenamiento completó las 4 épocas —el early stopping (paciencia 2) no llegó a dispararse— y load_best_model_at_end conservó el modelo de la época 3, la de mejor macro-F1 de validación.

Comparación de arquitecturas (contraste de hipótesis). Se repitió el ajuste con pysentimiento/robertuito-base-uncased sobre las mismas particiones y etiquetas (re-tokenizando con su propio tokenizador), obteniendo fidelidad **0,9330** en 5,9 minutos.

Modelo	Familia	Ajustado	Accuracy	macro-F1	Aciertos	Concordancia con maestro
BETO base	BETO	no	0,65	0,626	13/20	60 %
BETO ajustado	BETO	sí	0,70	0,669	14/20	85 %
RoBERTuito (maestro)	RoBERTuito	no	0,75	0,706	15/20	100 %
RoBERTuito ajustado	RoBERTuito	sí	0,75	0,734	15/20	90 %
Consenso (NB03)	ensamble	—	0,75	0,730	15/20	80 %




Figura 8. Calidad frente a etiquetas humanas (izquierda) y fidelidad al maestro (derecha).

Hipótesis	Resultado
H1 · RoBERTuito-ft imita mejor al maestro	✅ CONFIRMADA (0,9330 vs 0,9055) — comparte arquitectura y vocabulario con él
H2 · RoBERTuito-ft no supera al maestro	✅ CONFIRMADA (0,734 vs 0,706; $\Delta = +0,028 < \text{umbral } 0,05$)
H3 · Sin historia de mejora para RoBERTuito	✅ Su base carece de cabeza de sentimiento; la referencia sería el propio maestro (0,706), que es su techo. BETO sí tiene un «antes» comparable: 0,626 → 0,669

Conclusión de la fase. El techo de la destilación queda **empíricamente demostrado** y es independiente de la arquitectura del alumno. Se mantiene BETO como alumno principal por razones de **evaluabilidad** —es el único con una línea base comparable—, no de desempeño.

Variabilidad entre corridas. Repetir el mismo entrenamiento con idéntica semilla produce **14 o 15 aciertos de 20** (macro-F1 entre 0,669 y 0,708), por el no-determinismo del cómputo en GPU. Esta oscilación de $\pm 0,04$ **producida por el azar** es del mismo orden que las diferencias entre los modelos comparados: es la demostración empírica más clara de que **con $n = 20$ no es posible distinguir modelos cercanos**.

5.4 Análisis de falsos positivos

En evaluación docente los errores tienen costos asimétricos: un **falso positivo** (crítica clasificada como elogio) infla la percepción de desempeño y puede ocultar a un docente que requiere acompañamiento.

Situación medida (clase POS sobre el gold de 20): 6 verdaderos positivos · **1 falso positivo** · 1 falso negativo · precisión 0,857 · recall 0,857.

El falso positivo es «La clase estuvo bien.», predicho POS con $P(\text{POS}) = 0,993$, cuando el gold humano es NEU y el maestro también lo clasifica POS.

Test de separabilidad por umbral:

	P(POS)
Verdaderos POS	mínima 0,720 · mediana 0,989
Falso POS	máxima 0,993

¿Separables? **NO** — el falso positivo tiene confianza *superior* a varios aciertos reales.

Barrido de umbrales:

Umbral	Predice POS	Falsos POS	POS no detectados	macro-F1
0,50 (actual)	7	1	1	0,669
0,90	6	1	2	0,628
0,99	4	1	4	0,534
0,995	2	0	5	0,531

Umbral	Predice POS	Falsos POS	POS no detectados	macro-F1
0,998	0	0	7	0,368




Figura 9. Falsos positivos, verdaderos positivos perdidos y macro-F1 en función del umbral exigido para la clase POS.

Interpretación. (i) El error es **confiado, no incierto**: los umbrales solo funcionan cuando el error proviene de incertidumbre del modelo. (ii) El costo de eliminarlo es prohibitivo: el umbral más bajo que lo suprime (0,995) reduce los verdaderos positivos detectados de 6 a 2 y hunde el macro-F1 de 0,669 a 0,531; a 0,998 el modelo ya no predice ningún POS (0,368). (iii) El error **se hereda del maestro**. (iv) El caso es genuinamente fronterizo.

Conclusión metodológica. La reducción de falsos positivos en este punto **no es un problema de modelado sino de definición de etiquetas**. El ajuste de umbrales queda **descartado con evidencia**, y la vía efectiva es la anotación humana de casos fronterizos — que es exactamente la fase siguiente del proyecto.

5.5 Anotación humana: resultados del etiquetado

Volumen: 3 anotadores independientes · 749 anotaciones sobre 341 textos distintos (184 del bloque EVAL con triple anotación, 149 del bloque TRAIN con anotación simple y 8 anclas). Los 335 son el tamaño de diseño de la muestra.

Control de calidad por anotador (umbral de alerta: anclas < 7/8 o autoconsistencia < 6/8):

Anotador	Ítems	Sin etiqueta	Anclas correctas	Autoconsistencia	% marcados difíciles
A1	249	0	8/8 ✓	7/8	19 %
A2	250	0	8/8 ✓	6/8	3 %
A3	250	0	8/8 ✓	8/8	31 %

Ningún anotador cae por debajo de los umbrales de calidad; A2 queda justo en el límite de autoconsistencia (6/8). La dispersión en el porcentaje de ítems marcados como difíciles (3 % – 31 %) refleja distintos umbrales personales de duda, no descuido.

Exclusión de ítems no evaluables. Se excluyeron 7 comentarios mediante lista explícita y auditable, apoyada en el motivo `sin_sentido` marcado por los anotadores: 6 del bloque EVAL —«No.» (3/3 votos), «Ninguno.» (2/3), «Nada.», «Profesor.», «Está dibujando.» y «considerenos, por favor.» (1/3 cada uno)— y 1 del bloque TRAIN, «No tengo nada que decir sobre ella.» (1/1, con un solo anotador asignado). Se eliminaron además dos textos ilegibles.

Decisión metodológica. No se excluyeron los comentarios que confundieron a los anotadores pero **sí tienen polaridad** (sarcasmo, metáfora, elogio tibio). Eliminarlos habría dejado el gold solo con casos fáciles e **inflado artificialmente las métricas**.

Métricas de acuerdo inter-anotador:

Métrica	Valor	Rol
α de Krippendorff (nominal)	0,585	Titular — admite diseño incompleto y anotadores variables por ítem
α de Krippendorff (ordinal)	0,728	Diagnóstico
Fleiss κ	0,584	Convención de la literatura NLP
Cohen κ medio por pares	0,585	Diagnóstico
Acuerdo observado P_o	0,787	Obligatorio junto a κ
Acuerdo esperado por azar P_e	0,487	Explica la paradoja de κ

Interpretación según Landis & Koch: **acuerdo moderado** (rango 0,41–0,60).

Paradoja de kappa detectada y declarada. El acuerdo observado es alto (78,7 %) pero κ queda en 0,584 porque el azar esperado es elevado (0,487) debido al desbalance de clases. κ **debe interpretarse junto a P_o** , nunca por sepa-

rado: reportar solo κ llevaría a concluir que la anotación está rota cuando únicamente está sesgada.

Diagnóstico por tipo de desacuerdo. La brecha ordinal–nominal es **+0,143**, apenas por debajo del umbral de 0,15 que el propio script fija para declarar desacuerdo predominantemente adyacente; el diagnóstico automático emitido fue, por tanto, «acuerdo homogéneo entre tipos de desacuerdo». El **recuento directo sobre el bloque EVAL sí lo confirma**: de los 122 desacuerdos por pares, **92 son adyacentes** (POS↔NEU, NEU↔NEG) y solo 30 polares (POS↔NEG) — **75,4 % adyacentes**. El problema es, entonces, de **umbral de rúbrica** —corregible escribiendo reglas más precisas— y no de comprensión de la tarea.

Cohen κ por pares (detección de anotador atípico): $A1-A2 = 0,521 \cdot A1-A3 = 0,581 \cdot A2-A3 = 0,654$. La dispersión es moderada y no señala a ningún anotador como desviado.

Reparto del acuerdo y adjudicación del gold:

Situación	Ítems	%
Unanimidad (3/3)	124	69,7 %
Mayoría (2/1)	48	27,0 %
Sin mayoría (1/1/1) → ambiguos	6	3,4 %
Gold utilizable	172	

Distribución del gold: **POS 116 · NEG 36 · NEU 20**.

Hallazgo cualitativo. Los 6 ítems sin mayoría son **todos mixtos adversativos** («Bien, pero debería ser más amigable», «Es buena, pero debería ser más moderada al poner notas»). Cada anotador aplicó un criterio distinto: uno miró el elogio inicial, otro promedió, otro miró la crítica final. **Esto no es un fallo del equipo: es el hallazgo**. Confirma con datos que la frontera de los mixtos adversativos no está definida, y que ninguna métrica automática debería penalizar a un modelo por fallar ahí.

5.6 Modelo final: fine-tuning con verdad humana

Datos. Entrenamiento 148 comentarios (NEG 52 · NEU 22 · POS 74), subdivididos en 118 train / 30 validación. Evaluación: 172 comentarios (NEG 36 · NEU 20 · POS 116). **Fuga entre bloques: 0**.

Configuración. Base `pysentimiento/robertuito-sentiment-analysis`; *continued fine-tuning*; 4 épocas; lr **1e-5** (la mitad de lo habitual, para no destruir lo aprendido con tan pocos datos); batch 8; `max_length` 128; **entropía cruzada ponderada por clase** con pesos NEG 0,96 · NEU 2,19 · POS 0,67; *early stopping*; semilla 42; MPS. Duración: **20 segundos**.

Época	Pérdida train	Pérdida val	macro-F1 val
1	0,9245	0,9815	0,504
2	0,7321	0,9518	0,5494
3	0,6260	0,9468	0,5494
4	0,5815	0,9462	0,5494

La validación se estanca desde la época 2: con 118 ejemplos de entrenamiento el modelo agota rápidamente lo que puede aprender. **No es una limitación de método, sino de datos.**

Resultados sobre el gold humano (n = 172):

Modelo	Accuracy	macro-F1	Aciertos	Recall NEG
BETO destilado (NB04)	0,733	0,619	126/172	0,500
RoBERTuito (maestro público)	0,756	0,638	130/172	0,528
RoBERTuito ajustado (humano) 🏆	0,762	0,646	131/172	0,556




Figura 10. macro-F1 de los tres modelos sobre el conjunto de evaluación humano de 172 comentarios, 8,6 veces mayor que el disponible previamente.

Informe por clase del modelo ajustado:

Clase	Precisión	Recall	F1	Soporte
NEG	0,769	0,556	0,645	36
NEU	0,300	0,600	0,400	20
POS	0,934	0,853	0,892	116
macro avg	0,668	0,670	0,646	172
weighted avg	0,826	0,762	0,783	172

Prueba de significancia (McNemar) frente al maestro:

	Valor
Solo acierta el ajustado (b)	3
Solo acierta el maestro (c)	2
p-valor	1,000
Δ macro-F1	+0,007 (0,638 $\rightarrow$ 0,646)

Lectura honesta del resultado. El modelo ajustado mejora al maestro **en las tres métricas** y eleva el recall de la clase NEG de 0,528 a 0,556 —la detección de críticas, que es el objetivo del proyecto—. Sin embargo, con 148 ejemplos de entrenamiento la diferencia **no alcanza significancia estadística**. La afirmación defendible es «*el ajuste con verdad humana mejora consistentemente al maestro*», **no** «*superamos al maestro*».

Dos observaciones adicionales de valor. (i) Las métricas del benchmark original estaban **infladas**: RoBERTuito pasa de 0,706 sobre 20 comentarios a **0,638** sobre 172 — el conjunto pequeño era demasiado fácil. (ii) La clase **NEU no mejora**: el maestro y el modelo ajustado obtienen el mismo recall (0,600) y una precisión casi idéntica (0,293 frente a 0,300); el BETO destilado incluso la detecta mejor (recall 0,650) a costa de más falsos positivos. **Con 22 ejemplos NEU el ajuste no logra delimitar la clase**, y toda la ganancia del modelo final proviene de las clases NEG y POS.




Figura 11. Verificación reproducible de los tres modelos, generada al ejecutar el informe ejecutable `INFORME_FINAL.ipynb`.

5.7 Análisis institucional del sentimiento

Aplicando el pipeline a las 3.000 evaluaciones institucionales:


Distribución global: POS 888 (29,6 %) · NEU 1.220 (40,7 %) · NEG 892 (29,7 %).

Validación cruzada con los puntajes (ordenamiento coherente POS > NEU > NEG):

Sentimiento	Claridad	Metodología	Evaluación
POS	3,99	4,11	3,97
NEU	3,75	3,89	3,70
NEG	3,43	3,53	3,39

Cruce con la tendencia de desempeño: de las evaluaciones con comentario POS, solo el 6,2 % está «En riesgo»; de las NEG, el 32,7 %. La señal textual es coherente con la etiqueta institucional.

Comparación de esquemas de etiquetado (léxico del EDA vs gold standard): el score léxico concuerda con el gold en solo el **76,5 %** de las filas; 4 de 20 comentarios difieren, lo que cambia la polaridad de **705 filas (23,5 %)**. Aplicar el gold desplaza masa hacia NEG (léxico POS 971 $\rightarrow$ 677 · NEU 1.214 $\rightarrow$ 1.097 · NEG 815 $\rightarrow$ 1.226): **la lectura institucional real es más crítica** de lo que sugería el léxico. Las cifras de la distribución global de esta sección (888 / 1.220 / 892) corresponden al **consenso de los tres modelos**, no al léxico del EDA.



5.8 Eficiencia computacional

Experimento	Ejemplos	Duración	Hardware
Destilación BETO (NB04)	8.187	7,2 min	Apple Silicon (MPS)
Destilación RoBERTuito (NB04, capítulo 8.6)	8.187	5,9 min	Apple Silicon (MPS)
Fine-tuning humano (NB05)	118	20 s	Apple Silicon (MPS)
Modelo de tendencia (RF + calibración)	2.250	no cronometrado	CPU

Artefacto	Tamaño usable
modelo_sentimiento_humano (producción)	437,4 MB (435,2 model.safetensors + 2,2 tokenizador + configuración)
modelo_sentimiento_ft (destilado BETO)	440,2 MB
modelo_sentimiento_ft_robertuito	437,4 MB
modelo_tendencia_docente.pkl	3,5 MB

Todos los tamaños en unidades decimales (1 MB = 10⁶ bytes), medidos sumando los archivos del directorio. En unidades binarias el modelo de producción son 417,1 MiB.

Inferencia: CPU suficiente (no requiere GPU); ~2 vCPU y 4 GB de RAM; latencia del orden de decenas de milisegundos por comentario procesando en lotes; 100.000 comentarios ≈ minutos.

5.9 Modelos predictivos complementarios sobre métricas estructuradas

Fuente y crédito. Capítulo 4 del notebook del equipo exploracion/Consultas Estructuradas Con Metricas.ipynb (repositorio Capstone-Tech-Tailors/Analitica-Educativa). Este trabajo persigue los otros dos objetivos del Action Plan: **criterios de rotación** de un docente entre asignaturas (entregable a, vía el índice de egreso) y **demandas estudiantil** por asignatura (entregable c, vía «Estudiantes Aprobados») — señales que complementan el DOFA. El README del repositorio declara además la **deserción** para una clase específica (entregable b), que aquí se aborda mediante el análisis de correlaciones por asignatura; su modelado predictivo queda pendiente. Todas las cifras de esta subsección provienen de las salidas ejecutadas del notebook.

Datos y marco de modelado. Se usa un dataset **sintético ampliado** (`evaluaciones_docentes_sintetica_ampliada.csv`), distinto del institucional de 3.000 filas de la sección 3.1: añade variables operativas (clases pactadas/dictadas, horarios, asistencias, aprobados/perdieron/desistieron). Sobre él se construye un marco agregado por **docente-asignatura-semester** con métricas históricas derivadas (rachas de mejora, incidentes, índice de reingreso): **1.246 observaciones × 30 predictores** tras excluir la variable objetivo y Reingreso. El marco se agrega por docente-asignatura-semester y **no contiene ninguna variable de facultad**, de modo que la rotación se modela entre asignaturas sin poder restringirla a una misma facultad, como pide el enunciado del entregable (a).

Selección de las variables objetivo por correlación. Se exploraron las matrices de correlación del marco para elegir objetivos modelables. Idealmente se habría trabajado con «Reingresos a la Fecha», pero su comportamiento en la matriz llevó a optar por «Egresos a La Fecha» —proxy de la rotación docente, entregable (a)—; para el segundo modelo se eligió «Estudiantes Aprobados», que es la vía hacia la **demanda estudiantil** proyectada por asignatura, entregable (c).



Figura 14. Diez mayores correlaciones con «Egresos a La Fecha»: dominan las variables de racha («Semestres Sin Exceso en Horas Lectivas» 0,51; las rachas sin incidente de estudiantes, 0,47–0,50; la de comentarios negativos baja a 0,38) —señales moderadas y repartidas.



Figura 15. Nueve mayores correlaciones con «Estudiantes Aprobados»: el tamaño del grupo domina (`numero_estudiantes` 0,93 · «Cantidad de Grupos» 0,85 · «Horas Lectivas» 0,78) —anticipo de la identidad aritmética que se discute más abajo.

Idea aplicada: el índice de egreso. El concepto propuesto es predecir los egresos acumulados de un docente en una asignatura y dividirlos por los semestres que la ha dictado; cuanto mayor el índice, mayor la probabilidad de que **rote** y deje de dictarla el semestre entrante. El cálculo del índice como tal queda propuesto (la línea está preparada pero comentada en el notebook); lo entrenado y evaluado es el predictor de egresos acumulados.

Protocolo común de los dos experimentos: 8 regresores (Ridge, Lasso, ElasticNet, árbol de decisión, RandomForest, Gradient Boosting, KNN y SVR) con búsqueda de hiperparámetros GridSearchCV (5 pliegues, error cuadrático medio), partición 80/20 con semilla 42 y estandarización solo para los modelos sensibles a escala (lineales, KNN, SVR).

Resultados — «Egresos a La Fecha» (test, $n \approx 250$):

Modelo	RMSE	MAE	R ²
RandomForest 🏆	0,358	0,174	0,942
Gradient Boosting	0,382	0,195	0,934
Árbol de decisión	0,458	0,177	0,906

Modelo	RMSE	MAE	R ²
SVR (rbf)	0,779	0,571	0,727
Lasso	0,968	0,797	0,578
ElasticNet	0,972	0,802	0,574
Ridge	0,977	0,804	0,571
KNN	0,989	0,755	0,560

Campeón: **RandomForest** (`n_estimators 200 · max_depth None · min_samples_leaf 1 · min_samples_split 2`). La brecha entre los modelos de árbol (0,906–0,942) y los lineales ($\approx 0,57$) indica relaciones no lineales entre las rachas históricas y los egresos.

Dos precisiones de lectura. (i) La conclusión redactada en el notebook cita R^2 0,8542 con otros hiperparámetros: corresponde a una **corrida anterior**; aquí se reportan las salidas de la celda ejecutada (R^2 0,9422). (ii) «Egresos a La Fecha» se deriva de los reingresos acumulados y el «Índice de Reingreso» figura entre los predictores, de modo que existe un **acoplamiento parcial** entre objetivo y variables: el 0,94 debe leerse como techo optimista.

Resultados — «Estudiantes Aprobados» (test, $n \approx 250$): SVR lineal R^2 1,000 · MAE 0,004; Ridge R^2 1,000; Lasso R^2 0,999997; los de árbol quedan en 0,947–0,984.

Lectura honesta: el $R^2 = 1,000$ no es aprendizaje, es una identidad. En estos datos se cumple exactamente `numero_estudiantes = aprobados + perdieron + desistieron` (verificado fila a fila, diferencia máxima 0), y los tres términos de la derecha —salvo el objetivo— están entre los predictores junto con `numero_estudiantes`. El objetivo es entonces una **combinación lineal exacta de tres predictores**, y los modelos lineales se limitan a recuperarla: es **fuga de datos**, no capacidad predictiva. La Figura 15 ya lo anticipaba (`numero_estudiantes` con $r = 0,93$). **Recomendación:** excluir `numero_estudiantes`, `Estudiantes Perdieron` y `Estudiantes Desertados` del conjunto de predictores y reentrenar; el R^2 resultante, aunque menor, sí medirá lo que el modelo aporta. El valor demostrado de este ejercicio queda en el predictor de egresos.

Correlaciones a nivel de asignatura: la señal de deserción. El capítulo 4.3 del notebook agrega los datos por **asignatura-semester** (56 filas) y explora las tres variables de resultado académico. La de la deserción es la que da respaldo al entregable (b):



Figura 16. Correlaciones de «Estudiantes Que Desistieron» a nivel de asignatura-semester.

La deserción se explica sobre todo por el **volumen del curso**: número de estudiantes (0,76), cantidad de grupos (0,68) y estudiantes aprobados (0,68), seguidos de la carga lectiva —horas (0,63) y clases dictadas (0,63)— y de la asistencia típica (0,59). El dato revelador es el último: la correlación con «Estudiantes Que Perdieron» es apenas **0,17**, es decir que **desertar y reprobar son fenómenos distintos**. Quien abandona no es principalmente quien va perdiendo la materia; el abandono acompaña a los cursos grandes y de mayor carga. Para el entregable (b) esto delimita el camino: un modelo de deserción no puede apoyarse en el desempeño académico como predictor principal, sino en variables estructurales del curso.

Advertencia del propio notebook (capítulo 5): la muestra no es grande y parte de los datos de deserción y pérdida fueron sintetizados; los modelos deben reexplorarse con datos reales. Esta advertencia es coherente con las limitaciones L4 y L5 de este informe: sobre datos plantillados o sintetizados, las métricas describen la **viabilidad del método**, no el desempeño esperable en producción.

6 · Modelo de producción

6.1 Ficha técnica

Campo	Valor
Identificador	modelo_sentimiento_humano
Ubicación	analisis_sentimientos/models/modelo_sentimiento_humano/
Modelo base	pysentimiento/robertuito-sentiment-analysis (~110 M parámetros)
Método	Continued fine-tuning con etiquetas humanas (sin destilación)
Origen de las etiquetas	Anotación humana del equipo · 3 anotadores · $\alpha = 0,585$
Clases	NEG · NEU · POS (mapeo en <code>config.json</code> → la API devuelve etiquetas textuales)
Datos	118 train / 30 validación / 172 evaluación
Hiperparámetros	4 épocas · lr 1e-5 · batch 8 · max_length 128 · pérdida ponderada
Reproducibilidad	Semilla 42 · dispositivo MPS
Métricas	macro-F1 0,646 · accuracy 0,762 · recall NEG 0,556 (gold humano n=172)
Tamaño	437,4 MB (pesos + tokenizador + configuración) · 417,1 MiB

6.2 Justificación de la selección

1. **Es el mejor sobre la evaluación humana**, la única referencia independiente de cualquier modelo.
2. **Mejor detección de críticas** (recall NEG 0,556 vs 0,528): en evaluación docente, pasar por alto una crítica oculta a un docente que necesita acompañamiento y distorsiona el DOFA.
3. **Incorpora la rúbrica institucional**: aprendió de las decisiones del equipo, no del registro genérico de redes sociales.
4. **Apto para despliegue**: un solo modelo, inferencia en CPU, sin dependencias de servicios de terceros, mejorable con cada ronda de anotación sin cambiar la arquitectura.

6.3 Verificación del artefacto

El artefacto se recarga desde disco y reproduce las predicciones de la tabla siguiente (`INFORME_FINAL.ipynb`, celda 12); al evaluarlo sobre el gold de 172 devuelve exactamente las métricas de la sección 5.6. La prueba formal de identidad **disco vs. memoria** sobre 20 comentarios de control se ejecutó sobre `modelo_sentimiento_ft` (NB04, capítulo 9), no sobre este artefacto. Predicciones de demostración:

Comentario	Predicción	Confianza
La profesora explica con claridad y responde todas las dudas	POS	0,646
Cumple con el programa del curso	NEU	0,826
La clase estuvo bien	POS	0,897
Es buen profesor, pero debería preparar mejor los laboratorios	NEU	0,610
Nunca responde los correos y llega tarde	NEG	0,914
Se podría mejorar un poco el material de estudio	NEU	0,680

Lectura honesta de la demostración. El ajuste movió al modelo **hacia la rúbrica** —el caso mixto adversativo ya no se clasifica POS—, pero los casos emblemáticos «*La clase estuvo bien*» y «*Se podría mejorar*» aún no cruzan la frontera deseada. Es exactamente la limitación cuantificada en la sección 9.2 (L7 y L8) y lo que resolvería la siguiente ronda de anotación.


6.4 Paquete de despliegue

Se generó `modelo_sentimiento_humano.zip` (**404 MB decimales / 386 MiB**, 7 archivos: `model.safetensors`, `config.json`, `tokenizer.json`, `tokenizer_config.json`, `training_args.bin`, `info.json` y un archivo de instrucciones). Se excluyó el *checkpoint* de entrenamiento (1,3 GB, innecesario para inferencia). El ZIP **no está versionado en el repositorio** por su tamaño: se entrega por fuera de git. El paquete fue **verificado extrayéndolo en un directorio limpio y cargando el modelo desde ahí**, replicando exactamente lo que hará el servidor.

7 · Despliegue: el sistema en producción

El modelo no se sirve con un script suelto: está integrado en el **backend del equipo** (`src/app.py` del repositorio Capstone-Tech-Tailors/Analitica-Educativa), un servicio FastAPI con base de datos PostgreSQL y despliegue continuo en Azure. Esta sección documenta ese sistema con el foco puesto en cómo sirve el modelo de sentimiento.

7.1 Arquitectura del sistema



Componentes (todo verificado sobre el código del repositorio):

Componente	Implementación
API	FastAPI (src/app.py), título «Análítica Académica»
Base de datos	PostgreSQL asíncrono (SQLAlchemy 2 + asyncpg); una tabla, clases (PK id_curso_grupo); esquema versionado con Alembic
Ingesta	POST /etl : CSV → procesamiento en segundo plano por bloques de 500 filas → <i>UPSERT</i> (ON CONFLICT DO UPDATE). Los CSV nunca se versionan en git (información sensible)
Contenedor	Imagen base ghcr.io/benoitc/gunicorn:25.2.0 · worker uvicorn.workers.UvicornWorker · usuario no root
CI/CD	GitHub Actions: cada push a main → login OIDC en Azure → build de la imagen → techtailors.azurecr.io/analitica-educativa:<sha> → actualización del Container App
Infraestructura	Azure Container Apps: app analitica-educativa (región eastus2, según el FQDN público documentado en el README del repositorio), grupo de recursos sic-education-analytics , con documentación interactiva Swagger en /docs
Interfaz de usuario	Dashboard en PowerBI (repositorio entregable-visual), con demo pública — es el entregable (e) de la ficha del proyecto

Endpoints (14, agrupados por función):

Grupo	Endpoints	Función
Salud	GET /health/live · GET /health/ready	Sondas del contenedor; <i>ready</i> verifica la base de datos (SELECT 1 , 503 si cae)
Sentimiento (PLN)	POST /predecir_sentimientos · POST / analisis_foda	Clasificación por lotes y construcción del DOFA (sección 8.2)
Catálogo	GET /find_docentes · /find_asignaturas · /find_semestres	Valores distintos para los filtros del dashboard
Ingesta	POST /etl	Carga masiva del CSV institucional
Seguimiento	GET /seguimiento_docente (+ /count) · /seguimiento_docente_por_asignatura (+ /count) · /seguimiento_asignaturas (+ /count)	Agregaciones por docente, docente-asignatura y asignatura (puntajes medios, horas lectivas, conteos por tendencia, índices de carga y reingreso)

7.2 Cómo se sirve el modelo

El backend carga el modelo **una sola vez al arrancar** (patrón *lifespan* de FastAPI) y lo mantiene en memoria:

```
# src/app.py – extracto condensado de la función lifespan (la original añade mkdir y try/except)
HF_DEVICE = "mps" if torch.backends.mps.is_available() else ("cuda" if torch.cuda.is_available() else "cpu")
HF_MAX_LEN = 64

modelo_sentimientos_path = platformdirs.user_publicshare_path() / "ml_models" / "sentimientos"
if modelo_sentimientos_path.exists() and any(modelo_sentimientos_path.iterdir()):
    tokenizador_disco = AutoTokenizer.from_pretrained(modelo_sentimientos_path)
    modelo_disco = AutoModelForSequenceClassification.from_pretrained(modelo_sentimientos_path)
    ml_models["sentimientos"] = pipeline(
        "sentiment-analysis", model=modelo_disco, tokenizer=tokenizador_disco,
        device=HF_DEVICE, truncation=True, max_length=HF_MAX_LEN)
```

Propiedades operativas de este diseño:

- **Los pesos no viajan ni en git ni en la imagen Docker** (437 MB superan el límite de GitHub y engordarían cada build). Se cargan **exclusivamente desde disco local del contenedor**: `platformdirs.user_publicshare_path()/ml_models/sentimientos`, que con el usuario `unicorn` de la imagen resuelve a `/home/unicorn/Public/ml_models/sentimientos`.
- **Publicación del artefacto**: extraer el ZIP de la sección 6.4 en esa ruta — `unzip modelo_sentimiento_humano.zip -d /home/unicorn/Public/ml_models/sentimientos` — por volumen montado o copia al contenedor. El pipeline de CI/CD **no** sube el modelo.
- **Sin descarga automática**: no hay *fallback* a Hugging Face Hub. Si la carpeta no existe o está vacía, la aplicación **arranca igual** y los dos endpoints de sentimiento responden 503 — "Modelo no fue encontrado en el Almacenamiento"; el resto del sistema (ETL, seguimiento) sigue operativo. Este desacople es deliberado: la disponibilidad del dashboard no depende del modelo.
- **Dispositivo**: selección automática `mps → cuda → cpu`; en Azure Container Apps (sin GPU) la inferencia corre en CPU, suficiente para el patrón de carga por lotes semestral.
- **Inferencia por lotes reales**: `POST /predecir_sentimientos` recibe una lista JSON de comentarios y los pasa al pipeline **en una sola llamada**; responde `{comentario, sentimiento, probabilidad}` por elemento, con la etiqueta textual (POS/NEU/NEG) directamente del `config.json` del modelo, sin umbrales ni postprocesado.

Punto de alineación detectado. El backend fija `max_length = 64`, mientras que `modelo_sentimiento_humano` se entrenó y evaluó con `max_length = 128` (sección 5.6); 64 era el valor de la destilación del NB04. Con comentarios de mediana 4 palabras el truncamiento casi nunca actúa, pero los comentarios largos (hasta 199 palabras en el corpus) perderían la parte final — donde los mixtos adversativos concentran la crítica. **Recomendación:** subir `HF_MAX_LEN` a 128 en `src/app.py` para reproducir exactamente las condiciones de evaluación.

Reproducibilidad de la pila. Producción fija `transformers==5.14.1` y `torch==2.13.0`, **idénticas a las del entorno de entrenamiento**, de modo que no hay deriva de versión en la inferencia. Los recursos del servicio y el patrón de carga por lotes se detallan en la viñeta anterior y en la sección 5.8; la protección de los datos personales, en la sección 10.

8 · Aplicación: del sentimiento al DOFA

8.1 Metodología propuesta

El modelo es el **motor de clasificación**; el DOFA se construye agregando sus salidas por docente y combinándolas con el modelo de tendencia:

Cuadrante	Fuente	Regla de construcción
Fortalezas	Comentarios POS frecuentes + puntajes altos	Temas dominantes de los POS (claridad, dominio, trato)
Debilidades	Comentarios NEG recurrentes + dimensión de puntaje más baja	Temas dominantes de los NEG
Oportunidades	Críticas constructivas («debería...», «podría...»)	Peticiones de cambio accionables: materia prima del plan de mejora
Amenazas	Tendencia En riesgo + % NEG creciente entre semestres	Priorización del acompañamiento

Umbral de alerta sugerido: % NEG del docente en el cuartil superior o tendencia En riesgo; ambos simultáneamente indican prioridad máxima.

8.2 Implementación en el backend

El backend implementa el DOFA como servicio: `POST /analisis_foda` recibe la lista de comentarios de un docente — típicamente los comentarios distintos por docente-asignatura que devuelve `GET /seguimiento_docente_por_asignatura` —, los clasifica en lote con el modelo y los reparte por cuadrante:

```
# src/app.py (extracto real)
response["Fortalezas"] = list(foda.loc["POS", "Comentarios"]) if "POS" in sentimientos else []
response["Debilidades y Amenazas"] = list(foda.loc["NEG", "Comentarios"]) if "NEG" in sentimientos else []
response["Oportunidades"] = list(foda.loc["NEU", "Comentarios"]) if "NEU" in sentimientos else []
```

Características de la implementación: **tres cuadrantes** (Debilidades y Amenazas se fusionan en una sola lista), asignación por la etiqueta más probable de cada comentario (la probabilidad se descarta, sin umbral de confianza) y **deduplicación** de comentarios idénticos dentro de cada cuadrante — decisión acertada dado el plantillado del dataset institucional (sección 3.1). El JSON resultante es el que consume el dashboard PowerBI.

Diferencia con la metodología propuesta, declarada. La implementación asigna **Oportunidades** = NEU, mientras que la rúbrica de anotación (sección 4.2) etiqueta las críticas constructivas —«se podría mejorar...», «debería...», «falta...»— como NEG. En consecuencia, las peticiones de cambio accionables (la materia prima del plan de mejora según la sección 8.1) aparecen hoy en «Debilidades y Amenazas», y «Oportunidades» recoge los comentarios descriptivos y los elogios tibios. **Recomendación:** separar dentro del NEG las críticas constructivas mediante los patrones léxicos ya identificados («debería», «podría», «falta») y destinarlas a Oportunidades, o incorporar una cuarta etiqueta en la próxima ronda de anotación. Mientras tanto, la lectura correcta del cuadrante «Oportunidades» del sistema es «comentarios neutrales», no «críticas accionables».

8.3 Prototipo sobre datos reales

Aplicado al docente con mayor proporción de comentarios negativos del dataset institucional:

DOFA — Docente_4 52 evaluaciones · puntaje medio 3,56 · **52 % de comentarios NEG** · 27 % «En riesgo»

 **Fortalezas** — (5×) *La clase es muy dinámica y entretenida* · (1×) *Me inspiró a seguir aprendiendo sobre este tema* · (1×) *Excelente profesor, muy claro*

 **Debilidades** — (6×) *Asistencia puntual, pero falta dinamismo* · (4×) *Se podría mejorar un poco el material de estudio* · (3×) *Califica de forma injusta*

 **Oportunidades** — (6×) *Asistencia puntual, pero falta dinamismo* · (4×) *Se podría mejorar un poco el material de estudio* · (3×) *Falta mucha pedagogía*

 **Amenazas** — Tendencia «En riesgo» en el 27 % de sus evaluaciones frente al 20 % institucional. Evolución del % NEG: 2020: 50 % · 2021: 50 % · 2022: 38 % · **2023: 69 %**

8.4 Hallazgo aplicado: docentes «enmascarados»

El análisis por docente reveló un patrón que el sistema de puntajes no detecta: **cuatro docentes con puntaje por encima de la mediana pero con el porcentaje de comentarios negativos en el cuartil superior** — Docente_31 (puntaje 3,80 · 49,3 % NEG), Docente_3 (3,93 · 45,3 %), Docente_12 (3,76 · 45,1 %) y Docente_43 (3,84 · 44,9 %). Docente_3 figura incluso entre los mejores del EDA original.

La correlación entre el sentimiento medio por docente y su porcentaje de riesgo es moderada (Pearson −0,275; Spearman −0,296) y con el puntaje es de +0,490: **el texto aporta señal parcialmente independiente de los puntajes**, que es precisamente lo que justifica incorporarlo al DOFA.

9 · Limitaciones

Se declaran de forma explícita porque condicionan la interpretación de todos los resultados.

9.1 Limitaciones de los datos

#	Limitación	Impacto	Estado
L1	20 comentarios distintos en 3.000 filas (0,67 % de unicidad). El dataset institucional está plantillado/anonimizado	Impide medir diferencias entre modelos con potencia estadística sobre el texto institucional	Mitigada con el gold humano de 172 ítems (8,6×)
L2	Todo el texto del modelo de producción es traducido del inglés (dominio: universidad de Bangladesh): tanto el corpus de destilación como los 148 comentarios de entrenamiento y los 172 del gold humano	La anotación humana sustituyó el origen de las etiquetas , no el del texto: el desplazamiento de dominio y registro persiste en el entrenamiento y también en la evaluación , de modo que las métricas de la sección 5.6 no garantizan el mismo desempeño sobre comentarios reales de la U. del Rosario	Mitigada parcialmente por la auditoría de traducción (sección 3.4); su resolución de raíz es la prioridad 3 del trabajo futuro
L3	El gold humano contiene 20 ejemplos NEU en evaluación y 22 en entrenamiento	Precisión NEU de 0,300 y recall 0,600, idénticos a los del maestro : el ajuste no consigue delimitar la clase con tan pocos ejemplos	Abierta — requiere más anotación
L4	La etiqueta <code>tendencia_desempeno</code> es derivada por reglas , no observada	Las métricas del modelo de tendencia (0,915) son un techo artificial : el modelo reaprende la regla que generó la etiqueta	Documentada; requiere validación con datos de desempeño reales
L5	Los puntajes tienen distribución artificialmente uniforme (media 3,99 · desviación 0,54 · sin colas largas)	Los umbrales de la zona gris pueden no trasladarse a datos reales	Abierta

9.2 Limitaciones del modelo

#	Limitación	Evidencia
L6	La mejora sobre el maestro no es estadísticamente significativa	McNemar $b=3$, $c=2$, $p = 1,000$. La afirmación defendible es «mejora consistente», no «superioridad demostrada»
L7	Los mixtos adversativos siguen siendo el punto débil	6 de 172 ítems sin mayoría entre anotadores son todos de este tipo; el propio equipo no converge en ellos
L8	Los falsos positivos por elogio tibio no se resuelven con umbrales	El error es confiado ($P = 0,993$, por encima de varios aciertos reales); el umbral más bajo que lo elimina (0,995) reduce los verdaderos positivos detectados de 6 a 2 y hunde macro-F1 de 0,669 a 0,531
L9	Variabilidad entre corridas de $\pm 0,04$ en macro-F1 sobre $n=20$ (MPS, no determinista)	Dos ejecuciones idénticas del NB04 dieron 0,708 y 0,669: con 20 ítems, el ruido supera la diferencia entre modelos
L10	El techo de la destilación es estructural	H1 (más datos), H2 (menos regularización) y H3 (otra arquitectura) fueron falsables y ninguna cerró la brecha con el maestro
L11	Sin evaluación de sesgo por subgrupo (asignatura, facultad, género del docente)	No se dispone de metadatos demográficos ni de un gold suficientemente grande por subgrupo

9.3 Limitaciones del alcance

- El DOFA prototipado usa **agrupación por frecuencia de comentario**, no modelado temático (no hay suficientes textos distintos para justificar *topic modeling*).
- El backend está **desplegado con CI/CD**, pero el ciclo completo con datos de un semestre real —carga de pesos al contenedor incluida— aún no se ha ejecutado de extremo a extremo.
- El DOFA implementado asigna **Oportunidades = NEU**, que según la rúbrica no contiene las críticas constructivas sino los comentarios neutrales (diferencia declarada en la sección 8.2).
- El servicio fija **max_length = 64** frente a los 128 con que se evaluó el modelo (punto de alineación de la sección 7.2).
- El modelo de tendencia **no alcanza el objetivo de recall $\geq 0,985$** en el protocolo aleatorio (0,960 antes del ajuste de umbral, 0,966 después); sí lo alcanza en el protocolo temporal 2023 (0,993). Queda documentado como pendiente.

10 · Consideraciones éticas

Las salidas del modelo no son decisiones. Un sistema con macro-F1 de 0,646 y un recall NEG de 0,556 se equivoca de forma sistemática. Ninguna consecuencia laboral —renovación de contrato, evaluación de desempeño, sanción— debe derivarse automáticamente de sus predicciones. El uso legítimo es **priorizar dónde mira una persona**: señalar a qué docentes conviene acompañar y con qué evidencia textual.

Revisión humana obligatoria en el bucle. El DOFA generado es un borrador que un responsable académico lee, contrasta con el contexto (asignatura, tamaño de grupo, momento del plan de estudios) y edita antes de compartirlo con el docente.

Asimetría de errores. En este dominio, un falso negativo (no detectar una crítica real) es más costoso que un falso positivo: oculta un problema que la institución podría resolver. Por eso se priorizó el recall de la clase NEG en la selección del modelo, aun a costa de la precisión global.

Protección de datos. Los comentarios son opiniones sobre personas identificables. Se recomienda: seudonimizar los identificadores de docente antes de la inferencia, procesar en infraestructura controlada por la universidad, restringir el endpoint por token, y conservar solo los agregados necesarios para el DOFA —no los textos crudos vinculados a nombres.

Anonimato del estudiantado. Ningún artefacto del proyecto debe permitir reidentificar a quien escribió un comentario. En cursos pequeños, un comentario textual puede identificar a su autor; por eso los reportes deben publicarse agregados y con un mínimo de evaluaciones por docente.

Sesgo conocido y no medido. La literatura documenta sesgos de género y origen en las evaluaciones docentes escritas por estudiantes. Este proyecto **no pudo medirlos** (L11); un sistema que amplifique un sesgo presente en los datos lo convertiría en decisión institucional. Antes de un despliegue con consecuencias, es indispensable auditar el desempeño por subgrupo.

Transparencia. Los docentes evaluados deben saber que sus comentarios se procesan automáticamente, con qué finalidad, y tener derecho a revisar y objetar el DOFA resultante.

11 · Conclusiones

1. **El diagnóstico de los datos redefinió el proyecto.** Descubrir que las 3.000 evaluaciones contienen solo 20 comentarios distintos (0,67 % de unicidad) fue el hallazgo más importante: invalidó el plan de entrenar directamente sobre el dataset institucional y obligó a construir una fuente de verdad propia. Sin ese diagnóstico, cualquier métrica reportada habría sido una ilusión estadística.
2. **La destilación tiene un techo estructural y quedó demostrado, no supuesto.** El estudiante alcanzó una fidelidad de 0,9055 (BETO) y 0,9330 (RoBERTuito) frente al maestro, pero nunca lo igualó sobre el gold. Las tres hipótesis alternativas —más datos, menos regularización, otra arquitectura— se formularon de forma falsable y **ninguna cerró la brecha**. La conclusión es metodológica: *no se puede superar a un maestro aprendiendo únicamente de sus etiquetas*.
3. **Los falsos positivos por elogio tibio no son un problema de modelado.** El barrido de umbrales lo probó cuantitativamente: el error es confiado ($P = 0,993$, mayor que la de varios aciertos reales) y el umbral más bajo que lo elimina (0,995) deja solo 2 de los 6 verdaderos positivos y hunde macro-F1 de 0,669 a 0,531. **Es un problema de rúbrica**, y solo la anotación humana podía resolverlo.
4. **La anotación humana rompió el techo.** 749 anotaciones de 3 anotadores con α de Krippendorff de 0,585 (acuerdo moderado, con paradoja de kappa declarada y $P_o = 0,787$) produjeron un gold de 172 ítems, **8,6 veces mayor** que el disponible antes. Ese conjunto reveló además que las métricas del benchmark original estaban infladas: RoBERTuito baja de 0,706 sobre 20 ítems a 0,638 sobre 172.
5. **El modelo final mejora al maestro de forma consistente, pero sin significancia estadística.** `modelo_sentimiento_humano` obtiene macro-F1 0,646 · accuracy 0,762 · recall NEG 0,556, mejor que el maestro en las tres métricas, con McNemar $p = 1,000$. La afirmación honesta —y la que sostiene este informe— es que **el ajuste con verdad humana funciona en la dirección correcta y necesita más datos anotados para demostrarlo con potencia**.
6. **La brecha ordinal–nominal de +0,143 identificó exactamente dónde invertir.** Los desacuerdos entre anotadores son adyacentes, no polares: el problema es de umbral de rúbrica, no de comprensión. Los 6 ítems sin mayoría son todos mixtos adversativos. Eso convierte «mejorar el modelo» en una tarea concreta: escribir reglas de decisión para los mixtos y volver a anotar.
7. **La auditoría del análisis exploratorio evitó cuatro errores publicables:** una fuga de información (`delta_semestre`), un ranking de importancia invalidado por colinealidad, una variable sin señal real (`id_docente`, V de Cramér 0,119 con $p = 0,813$) y una ventaja del aprendizaje automático que no resiste una prueba de significancia (McNemar $p = 0,280$). La verificación adversarial no es burocracia: cambió conclusiones.
8. **El sentimiento aporta señal parcialmente independiente de los puntajes**, y ahí está su valor para el DOFA. Cuatro docentes tienen puntaje por encima de la mediana y porcentaje de comentarios negativos en el cuartil superior —casos que el sistema de puntajes no detecta—. En la frontera de decisión real ($[3,9 - 4,5]$), incorporar el sentimiento aporta +0,04 de macro-F1.
9. **El artefacto está verificado y su sistema de servicio, desplegado:** 437 MB, inferencia en CPU (2 vCPU · 4 GB), ZIP de 404 MB probado extrayéndolo en un directorio limpio, e integrado en el backend FastAPI con despliegue continuo en Azure Container Apps (sección 7). Falta **completar la puesta en producción**: publicar los pesos en el contenedor —hasta entonces los endpoints de sentimiento devolverán 503—, alinear `max_length` a 128 y ejecutar el ciclo completo con datos de un semestre real (sección 9.3).

12 · Trabajo futuro

Ordenado por relación entre impacto y esfuerzo. La columna «Cierra» indica qué limitaciones de la sección 9 resuelve cada línea de trabajo.

#	Línea de trabajo	Impacto · esfuerzo	Qué hacer	Cierra
1	Ampliar el gold anotado	alto · medio	Duplicar el conjunto humano a 300–400 ítems, con énfasis en NEU y en mixtos adversativos. Con ~150 ítems más por clase, McNemar tendría potencia para decidir si la mejora sobre el maestro es real	L3 · L6 · L7
2	Refinar la rúbrica de mixtos adversativos	alto · bajo	Redactar reglas explícitas («si la crítica pide un cambio concreto, la etiqueta es la de la crítica») y re-anotar los 48 ítems de mayoría simple: debería elevar α por encima de 0,70 sin anotar nada nuevo	L7
3	Recolectar comentarios institucionales reales	alto · externo	Solicitar a la universidad un volcado sin plantillar de un semestre; permite reentrenar sobre el dominio objetivo en lugar de un corpus traducido	L1 · L2 · L5

#	Línea de trabajo	Impacto · esfuerzo	Qué hacer	Cierra
4	Auditoría de sesgo por subgrupo	alto · medio	Medir macro-F1 y recall NEG por asignatura, facultad y —si es legalmente posible y con consentimiento— género del docente. Requisito previo a cualquier despliegue con consecuencias	L11
5	Validar la tendencia con desempeño observado	medio	Sustituir la etiqueta derivada por reglas por una señal real (evolución de puntajes, permanencia, resultados de aprendizaje). Sin esto, el 0,915 no es interpretable	L4
6	Análisis por aspectos (ABSA)	medio · alto	Pasar de polaridad global a polaridad por aspecto (metodología · evaluación · trato · material): el DOFA distinguiría «explica bien pero califica injustamente» de un mixto indiferenciado. Requiere el gold de la prioridad 1	—
7	Completar la puesta en producción y monitorear	medio · bajo	Cargar los pesos en /home/gunicorn/Public/ml_models/sentimientos , alinear max_length a 128, redirigir las críticas constructivas al cuadrante Oportunidades (sección 8.2) y alertar ante desviaciones (drift). Cada semestre anotado alimenta la siguiente versión	—

13 · Referencias

Datos

1. Rahman, M. et al. *Students' Feedback on Teaching Quality — AIUB* [dataset]. Mendeley Data. Licencia CC BY-NC 3.0. (Corpus origen del subconjunto de 100.000 filas traducido al español.)
2. Universidad del Rosario / equipo Tech Tailors. *evaluaciones_docentes.csv* — 3.000 evaluaciones docentes plantilladas y anonimizadas (2020–2023).

Modelos y arquitecturas

3. Devlin, J., Chang, M.-W., Lee, K. & Toutanova, K. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. NAACL-HLT.
4. Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H. & Pérez, J. (2020). *Spanish Pre-Trained BERT Model and Evaluation Data (BETO)*. PML4DC @ ICLR 2020.
5. Pérez, J. M., Giudici, J. C. & Luque, F. (2021). *pysentimiento: A Python Toolkit for Sentiment Analysis and Social NLP tasks*. arXiv:2106.09462. (RoBERTuito.)
6. Barbieri, F., Espinosa-Anke, L. & Camacho-Collados, J. (2022). *XLMT: Multilingual Language Models in Twitter for Sentiment Analysis and Beyond*. LREC.
7. Liu, Y. et al. (2019). *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. arXiv:1907.11692.

Métodos

8. Hinton, G., Vinyals, O. & Dean, J. (2015). *Distilling the Knowledge in a Neural Network*. NIPS Deep Learning Workshop. (Destilación maestro→estudiante.)
9. Ratner, A., Bach, S. H., Ehrenberg, H., Fries, J., Wu, S. & Ré, C. (2017). *Snorkel: Rapid Training Data Creation with Weak Supervision*. VLDB. (Supervisión débil.)

10. Ruder, S. & Howard, J. (2018). *Universal Language Model Fine-tuning for Text Classification (ULMFiT)*. ACL.

Evaluación y acuerdo

11. Krippendorff, K. (2004). *Content Analysis: An Introduction to Its Methodology* (2ª ed.). Sage. (a nominal y ordinal.)
12. Fleiss, J. L. (1971). *Measuring nominal scale agreement among many raters*. Psychological Bulletin, 76(5), 378–382.
13. Cohen, J. (1960). *A Coefficient of Agreement for Nominal Scales*. Educational and Psychological Measurement, 20(1), 37–46.
14. Landis, J. R. & Koch, G. G. (1977). *The Measurement of Observer Agreement for Categorical Data*. Biometrics, 33(1), 159–174. (Escala de κ.)
15. Feinstein, A. R. & Cicchetti, D. V. (1990). *High agreement but low kappa: I. The problems of two paradoxes*. Journal of Clinical Epidemiology, 43(6), 543–549. (Paradoja de kappa.)
16. Dietterich, T. G. (1998). *Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms*. Neural Computation, 10(7), 1895–1923. (McNemar.)
17. Niculescu-Mizil, A. & Caruana, R. (2005). *Predicting Good Probabilities with Supervised Learning*. ICML. (Calibración isotónica.)
18. Brier, G. W. (1950). *Verification of Forecasts Expressed in Terms of Probability*. Monthly Weather Review, 78(1), 1–3.

Herramientas

19. Wolf, T. et al. (2020). *Transformers: State-of-the-Art Natural Language Processing*. EMNLP (System Demonstrations). Hugging Face.
20. Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR, 12, 2825–2830.
21. Anthropic (2025). *Claude* — traducción EN→ES del corpus (sección 3.4) y asistencia de desarrollo.

Fin del informe técnico

Proyecto Analítica Educativa · Equipo Tech Tailors
Samsung Innovation Campus — Capstone Project